02线性模型

李祎

liyi@dlut.edu.cn



目录




- □ 线性回归
 - 最小二乘法
- □ 二分类任务
 - 对数几率回归
 - 线性判别分析
- □ 多分类学习
 - \(\forall \) \(\fo
 - 一对其余
 - 多对多
- □ 类别不平衡问题



Image Recognition:

$$f($$
 $)=$ "cat"



Credit: slide by Hung-yi Lee



Different Tasks (任務)


Step 0: What kind of function do you want to find?

Step 1: define a set of function

Step 2: goodness of function

Step 3: pick the best function

就好像把大象放进冰箱



Credit: slide by Hung-yi Lee



Different Tasks (任務)

Step 0: What kind of function do you want to find?


Step 1: define a set of function



Step 2: goodness of function



Step 3: pick the best function



Step 1:

$$f(x) = wx + b$$

Step 2: 回归误差

$$e_i = y_i - (wx_i + b)$$

Step 3:


$$(w^*, b^*) = \arg\min_{w,b} \sum_{i=1}^m (y_i - wx_i - b)^2$$

线性回归

线性回归



- □ 给定数据集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \dots, (\boldsymbol{x}_m, y_m)\}$ 其中 $\boldsymbol{x}_i = (x_{i1}; x_{i2}; \dots; x_{id}), y_i \in \mathbb{R}$
- □ 线性回归 (linear regression) 目的
 - 学得一个线性模型以尽可能准确地预测实值输出标记



线性回归



■ 单一属性的线性回归目标

$$f(x) = wx_i + b$$
 使得 $f(x_i) \simeq y_i$

□ 参数/模型估计: 最小二乘法 (least square method)

$$(w^*, b^*) = \underset{(w,b)}{\operatorname{arg \, min}} \sum_{i=1}^{m} (f(x_i) - y_i)^2$$
$$= \underset{(w,b)}{\operatorname{arg \, min}} \sum_{i=1}^{m} (y_i - wx_i - b)^2$$

线性回归 - 最小二乘法



□ 最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^{m} (y_i - wx_i - b)^2$$

 \square 分别对 w 和 b 求导,可得

$$\frac{\partial E_{(w,b)}}{\partial w} = 2\left(w\sum_{i=1}^{m} x_i^2 - \sum_{i=1}^{m} (y_i - b)x_i\right)$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2\left(mb - \sum_{i=1}^{m} (y_i - wx_i)\right)$$

线性回归 - 最小二乘法



□ 得到闭式 (closed-form) 解

$$w = \frac{\sum_{i=1}^{m} y_i (x_i - \bar{x})}{\sum_{i=1}^{m} x_i^2 - \frac{1}{m} \left(\sum_{i=1}^{m} x_i\right)^2}$$

$$b = \frac{1}{m} \sum_{i=1}^{m} (y_i - wx_i)$$

其中

$$\bar{x} = \frac{1}{m} \sum_{i=1}^{m} x_i$$

一般形式



□ 线性模型一般形式

$$f(\mathbf{x}) = w_1 x_1 + w_2 x_2 + \ldots + w_d x_d + b$$

 $\boldsymbol{x}=(x_1;x_2;\ldots;x_d)$ 是由属性描述的示例,其中 x_i 是 \boldsymbol{x} 在第i个属性上的取值

□ 向量形式

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathrm{T}} \boldsymbol{x} + b$$

其中 $\boldsymbol{w} = (w_1; w_2; \dots; w_d)$

多元线性回归



□ 给定数据集

$$D = \{ (\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \dots, (\boldsymbol{x}_m, y_m) \}$$
$$\boldsymbol{x}_i = (x_{i1}; x_{i2}; \dots; x_{id}) \ y_i \in \mathbb{R}$$

□ 多元线性回归目标

$$f(\boldsymbol{x}_i) = \boldsymbol{w}^{\mathrm{T}} \boldsymbol{x}_i + b$$
 使得 $f(\boldsymbol{x}_i) \simeq y_i$

多元线性回归



lacksquare 把 $oldsymbol{w}$ 和 b 吸收入向量形式 $\hat{oldsymbol{w}}=(oldsymbol{w};b)$,数据集表示为

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \boldsymbol{x}_1^{\mathrm{T}} & 1 \\ \boldsymbol{x}_2^{\mathrm{T}} & 1 \\ \vdots & \vdots \\ \boldsymbol{x}_m^{\mathrm{T}} & 1 \end{pmatrix}$$

$$\boldsymbol{y} = (y_1; y_2; \dots; y_m)$$

多元线性回归 - 最小二乘法



□ 最小二乘法 (least square method)

$$\hat{\boldsymbol{w}}^* = \operatorname*{arg\,min}_{\hat{w}} \left(\boldsymbol{y} - \mathbf{X} \hat{\boldsymbol{w}}^{\mathrm{T}} \right) \left(\boldsymbol{y} - \mathbf{X} \hat{\boldsymbol{w}} \right)$$

$$\hat{m{\varphi}} E_{\hat{m{w}}} = \left(m{y} - \mathbf{X}\hat{m{w}}
ight)^{\mathrm{T}} \left(m{y} - \mathbf{X}\hat{m{w}}
ight)$$
 , 对 $\hat{m{w}}$ 求导得到

$$\frac{\partial E_{\hat{\boldsymbol{w}}}}{\partial \hat{\boldsymbol{w}}} = 2\mathbf{X}^{\mathrm{T}} \left(\mathbf{X} \hat{\boldsymbol{w}} - \boldsymbol{y} \right)$$

令上式为零可得 \hat{w} 最优解的闭式解

多元线性回归 - 满秩讨论



 \mathbf{L} $\mathbf{X}^{\mathrm{T}}\mathbf{X}$ 是满秩矩阵或正定矩阵,则

$$\hat{oldsymbol{w}}^* = \left(\mathbf{X}^{\mathrm{T}} \mathbf{X}
ight)^{-1} \mathbf{X}^{\mathrm{T}} oldsymbol{y}$$

其中 $\left(\mathbf{X}^{\mathrm{T}}\mathbf{X}\right)^{-1}$ 是 $\mathbf{X}^{\mathrm{T}}\mathbf{X}$ 的逆矩阵,线性回归模型为

$$f\left(\hat{oldsymbol{x}}_i
ight) = \hat{oldsymbol{x}}_i^{\mathrm{T}} \left(\mathbf{X}^{\mathrm{T}}\mathbf{X}
ight)^{-1} \mathbf{X}^{\mathrm{T}}oldsymbol{y}$$


- \mathbf{L} $\mathbf{X}^{\mathrm{T}}\mathbf{X}$ 不是满秩矩阵,多个解,怎么选?
 - 根据归纳偏好选择解(参见1.4节)
 - 引入正则化: 对解空间的一种限制
 - 正则化参考资料
 - 吴恩达《机器学习》-正则化 https://www.bilibili.com/video/av55276229
 - L1&L2正则化详解 https://www.bilibili.com/video/av77106463?from=search&seid=4369320229005019988
 - 什么是L1 L2正则化? https://www.bilibili.com/video/av16009446?from=search&seid=4369320229005019988

线性模型特点



- □ 形式简单、易于建模
- □ 可解释性
- □ 非线性模型的基础
 - 引入层级结构或高维映射

- 对异常点鲁棒性差
 - 随机取样一致
 - (Random Sample Consensus, RANSAC)
 - 鲁棒回归 (Robust Regression)



线性的含义



$$y = wx + b$$

线性?



$$y = w_1 x + w_2 x^2 + w_3 x^3 + b$$

线性?



$$x_1 = x$$
, $x_2 = x^2$, $x_3 = x^3$
 $y = w_1 x_1 + w_2 x_2 + w_3 x_3 + b$

线性?




- 线性并不指对输入变量的线性,而是指对参数空间的线性。也就说对于输入来说,完全可以对先对其进行非线性变换,再进行线性组合。从这个角度来说, 线性模型完全具有描述非线性的能力。
- □ 通用非线性化方法:核学习方法 (Kernel-based Learning Algorithms)

对数线性回归



■ 输出标记的对数为线性模型逼近的目标



$$\ln y = \boldsymbol{w}^{\mathrm{T}} \boldsymbol{x} + b$$

$$\boldsymbol{y} = \boldsymbol{w}^{\mathrm{T}} \boldsymbol{x} + b$$

广义线性模型



□一般形式

$$y = g^{-1} \left(\boldsymbol{w}^{\mathrm{T}} \boldsymbol{x} + b \right)$$

- \square $g(\cdot)$ 称为联系函数 (link function)
 - 单调可微函数

□ 对数线性回归是 $g(\cdot) = \ln(\cdot)$ 时广义线性模型的特例

Logistic 回归

用回归模型完成二分类任务



□ 预测值与输出标记

$$z = \boldsymbol{w}^{\mathrm{T}} \boldsymbol{x} + b \qquad y \in \{0, 1\}$$

- □ 寻找函数将分类标记与线性回归模型输出联系起来
- □ 最理想的函数——单位阶跃函数

$$y = \left\{ egin{array}{lll} 0, & z < 0; & \hline -1 & 0 & 1 & x \ 0.5, & z = 0; & & & & & & & & & & \\ 1, & z > 0, & & & & & & & & & & \\ \end{array}
ight.$$

预测值大于零就判为正例,小于零就判为反例,预测值为临界值零则可任意判别


二分类任务



- □ 单位阶跃函数缺点
 - 不连续
- □ 替代函数——对数几率函数 (logistic function)
 - 单调可微、任意阶可导

单位阶跃函数与对数几率函数的比较

$$y = \frac{1}{1 + e^{-z}}$$



对数几率回归

名字虽是"回归", 实际是分类方法



□ 运用对数几率函数


$$y = \frac{1}{1 + e^{-z}}$$
 要为 $y = \frac{1}{1 + e^{-(\mathbf{w}^{\mathrm{T}}\mathbf{x} + b)}}$

- □ 对数几率 (log odds)
 - 样本作为正例的相对可能性的对数

$$\ln \frac{y}{1-y}$$
 看作是x为正例的可能性

- □ 对数几率回归优点
- 无需事先假设数据分布
- 可得到"类别"的近似概率预测
- 可直接应用现有数值优化算法求取最优解

如何确定参数?极大似然法



对数几率回归 - 极大似然法 《 太连程之太学 人工智能学院 School of Artificial Intelligence, Dalian University of Technology



对数几率

$$ln\frac{y}{1-y} = ln\frac{p(y=1 \mid \boldsymbol{x})}{p(y=0 \mid \boldsymbol{x})} = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

显然有

$$p(y = 1 \mid \boldsymbol{x}) = \frac{e^{\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b}}{1 + e^{\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b}}$$

$$p(y = 0 \mid \boldsymbol{x}) = \frac{1}{1 + e^{\boldsymbol{w}^{\mathrm{T}} \boldsymbol{x} + b}}$$

对数几率回归 - 极大似然法



- 极大似然法 (maximum likelihood)
 - 给定数据集

$$\left\{ \left(\boldsymbol{x}_{i},y_{i}\right)\right\} _{i=1}^{m}$$

 $p(y = 1 \mid \boldsymbol{x}) = \frac{e^{\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b}}{1 + e^{\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b}}$ $p(y = 0 \mid \boldsymbol{x}) = \frac{1}{1 + e^{\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b}}$

- 最大化样本属于其真实标记的概率
 - 最大化对数似然函数

$$\ell(\boldsymbol{w}, b) = \sum_{i=1}^{m} \ln p(y_i \mid \boldsymbol{x}_i; \boldsymbol{w}_i, b)$$

对数几率回归 - 极大似然法



$$\ell\left(oldsymbol{w},b
ight) = \sum_{i=1}^{m} \ln \, p\left(y_i \mid oldsymbol{x}_i; oldsymbol{w}_i, b
ight)$$

- ullet 令 $oldsymbol{eta}=(oldsymbol{w};b)$, $\hat{oldsymbol{x}}=(oldsymbol{x};1)$,则 $oldsymbol{w}^{\mathrm{T}}oldsymbol{x}+b$ 可简写为 $oldsymbol{eta}^{\mathrm{T}}\hat{oldsymbol{x}}$
- \mathbb{P} $p_1(\hat{\boldsymbol{x}}_i;\boldsymbol{\beta}) = p(y = 1 \mid \hat{\boldsymbol{x}};\boldsymbol{\beta})$ $p_0(\hat{\boldsymbol{x}}_i;\boldsymbol{\beta}) = p(y = 0 \mid \hat{\boldsymbol{x}};\boldsymbol{\beta}) = 1 p_1(\hat{\boldsymbol{x}}_i;\boldsymbol{\beta})$

 $y \in \{0,1\}$ 则似然项可重写为 $p(y_i \mid \boldsymbol{x}_i; \boldsymbol{w}_i, b) = y_i p_1(\hat{\boldsymbol{x}}_i; \boldsymbol{\beta}) + (1 - y_i) p_0(\hat{\boldsymbol{x}}_i; \boldsymbol{\beta})$

● 最大化对数似然函数 等价于 最小化负对数似然函数

$$\ell\left(\boldsymbol{\beta}\right) = \sum_{i=1}^{m} \left(-y_{i}\boldsymbol{\beta}^{\mathrm{T}}\hat{\boldsymbol{x}}_{i} + \ln\left(1 + e^{\beta^{\mathrm{T}}\hat{\boldsymbol{x}}_{i}}\right)\right)$$

对数几率回归



$$\ell\left(\boldsymbol{\beta}\right) = \sum_{i=1}^{m} \left(-y_i \boldsymbol{\beta}^{\mathrm{T}} \hat{\boldsymbol{x}}_i + \ln\left(1 + e^{\beta^{\mathrm{T}} \hat{\boldsymbol{x}}_i}\right)\right)$$

高阶可导连续凸函数,梯度下降法/牛顿法

□ 求解得

$$\boldsymbol{\beta}^* = \operatorname*{arg\,min}_{\boldsymbol{\beta}} \ell\left(\boldsymbol{\beta}\right)$$

□ 例如, 牛顿法第t+1轮迭代解的更新公式

$$oldsymbol{eta}^{t+1} = oldsymbol{eta}^t - \left(rac{\partial^2 \ell\left(oldsymbol{eta}
ight)}{\partial oldsymbol{eta}\partial oldsymbol{eta}^{\mathrm{T}}}
ight)^{-1} rac{\partial \ell\left(oldsymbol{eta}
ight)}{\partial oldsymbol{eta}}$$


其中关于 β 的一阶、二阶导数分别为

$$\frac{\partial \ell\left(\boldsymbol{\beta}\right)}{\partial \boldsymbol{\beta}} = -\sum_{i=1}^{m} \hat{\boldsymbol{x}}_{i} \left(y_{i} - p_{1}\left(\hat{\boldsymbol{x}}_{i}; \boldsymbol{\beta}\right)\right)$$
$$\frac{\partial^{2} \ell\left(\boldsymbol{\beta}\right)}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^{\mathrm{T}}} = \sum_{i=1}^{m} \hat{\boldsymbol{x}}_{i} \hat{\boldsymbol{x}}_{i}^{\mathrm{T}} p_{1}\left(\hat{\boldsymbol{x}}_{i}; \boldsymbol{\beta}\right) \left(1 - p_{1}\left(\hat{\boldsymbol{x}}_{i}; \boldsymbol{\beta}\right)\right)$$

线性判别分析



□ 线性判别分析 (Linear Discriminant Analysis) [Fisher, 1936]



LDA也可被视为一种 监督降维技术



□ LDA的思想

- 欲使同类样例的投影点尽可能接近,可以让同类样例投影点的协方差尽可能小
- 欲使异类样例的投影点尽可能远离,可以让类中心之间的距离尽可能大

□ 一些变量

- 第i类示例的集合 X_i
- 第i类示例的均值向量 μ_i
- ullet 第i类示例的协方差矩阵 $oldsymbol{\Sigma}_i$
- ullet 两类样本的中心在直线上的投影 $:oldsymbol{w}^{\mathrm{T}}oldsymbol{\mu}_0$ 和 $oldsymbol{w}^{\mathrm{T}}oldsymbol{\mu}_1$
- ullet 两类样本的协方差: $oldsymbol{w}^{\mathrm{T}}oldsymbol{\Sigma}_{0}oldsymbol{w}$ 和 $oldsymbol{w}^{\mathrm{T}}oldsymbol{\Sigma}_{1}oldsymbol{w}$



□ 最大化目标

$$J = rac{\left\|oldsymbol{w}^{\mathrm{T}}oldsymbol{\mu}_0 - oldsymbol{w}^{\mathrm{T}}oldsymbol{\mu}_1
ight\|_2^2}{\left\|oldsymbol{w}^{\mathrm{T}}oldsymbol{\Sigma}_0oldsymbol{w} + oldsymbol{w}^{\mathrm{T}}oldsymbol{\Sigma}_1oldsymbol{w}
ight)}
ight\|_2^2} = rac{oldsymbol{w}^{\mathrm{T}}\left(oldsymbol{\mu}_0 - oldsymbol{\mu}_1
ight)\left(oldsymbol{\mu}_0 - oldsymbol{\mu}_1
ight)^{\mathrm{T}}oldsymbol{w}}{oldsymbol{w}^{\mathrm{T}}\left(oldsymbol{\Sigma}_0 + oldsymbol{\Sigma}_1
ight)oldsymbol{w}}$$

□ 类内散度矩阵

$$egin{aligned} \mathbf{S}_w &= oldsymbol{\Sigma}_0 + oldsymbol{\Sigma}_1 \ &= \sum_{oldsymbol{x} \in X_0} \left(oldsymbol{x} - oldsymbol{\mu}_0
ight) \left(oldsymbol{x} - oldsymbol{\mu}_0
ight)^{\mathrm{T}} + \sum_{oldsymbol{x} \in X_1} \left(oldsymbol{x} - oldsymbol{\mu}_1
ight) \left(oldsymbol{x} - oldsymbol{\mu}_1
ight)^{\mathrm{T}} \end{aligned}$$

□ 类间散度矩阵

$$\mathbf{S}_b = \left(oldsymbol{\mu}_0 - oldsymbol{\mu}_1
ight) \left(oldsymbol{\mu}_0 - oldsymbol{\mu}_1
ight)^{\mathrm{T}}$$



□ 广义瑞利商 (generalized Rayleigh quotient)

$$J = rac{oldsymbol{w}^{\mathrm{T}} \mathbf{S}_b oldsymbol{w}}{oldsymbol{w}^{\mathrm{T}} \mathbf{S}_w oldsymbol{w}}$$

 $\square \diamondsuit w^{\mathrm{T}} \mathbf{S}_w w = 1$,最大化广义瑞利商等价形式为

$$\min_{oldsymbol{w}} - oldsymbol{w}^{\mathrm{T}} \mathbf{S}_b oldsymbol{w}$$

s.t.
$$\boldsymbol{w}^{\mathrm{T}} \mathbf{S}_{w} \boldsymbol{w} = 1$$

□ 运用拉格朗日乘子法

$$\mathbf{S}_b \boldsymbol{w} = \lambda \mathbf{S}_w \boldsymbol{w}$$



□ 同向向量

$$\mathbf{S}_b oldsymbol{w} = \lambda \left(oldsymbol{\mu}_0 - oldsymbol{\mu}_1
ight)$$

□ 结果

$$\boldsymbol{w} = \mathbf{S}_w^{-1} \left(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1 \right)$$

- □求解
 - 奇异值分解 $\mathbf{S}_w = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$
- □ LDA的贝叶斯决策论解释
 - 两类数据同先验、满足高斯分布且协方差相等时,LDA达到最优分类

LDA推广 - 多分类任务



- □ 假设N类,第 i 类示例数为m_i
- □ 全局散度矩阵

$$egin{aligned} \mathbf{S}_t &= \mathbf{S}_b + \mathbf{S}_w \ &= \sum_{i=1}^m \left(oldsymbol{x}_i - oldsymbol{\mu}
ight) \left(oldsymbol{x}_i - oldsymbol{\mu}
ight)^T \end{aligned}$$

 $lacksymbol{\square}$ 类内散度矩阵 $\mathbf{S}_w = \sum_{i=1}^N \mathbf{S}_{w_i}$

□ 求解得

$$\mathbf{S}_b = \mathbf{S}_t - \mathbf{S}_w$$

$$= \sum_{i=1}^N m_i \left(\boldsymbol{\mu}_i - \boldsymbol{\mu} \right) \left(\boldsymbol{\mu}_i - \boldsymbol{\mu} \right)^T$$


LDA推广 - 多分类任务



□ 优化目标

$$\max_{\mathbf{W}} \frac{\operatorname{tr}\left(\mathbf{W}^{\mathrm{T}}\mathbf{S}_{b}\mathbf{W}\right)}{\operatorname{tr}\left(\mathbf{W}^{\mathrm{T}}\mathbf{S}_{w}\mathbf{W}\right)}$$

其中 $\mathbf{W} \in \mathbb{R}^{d \times (N-1)}$



 \mathbf{W} 的闭式解则是 $\mathbf{S}_{w}^{-1}\mathbf{S}_{b}$ 的 $\mathbf{N-1}$ 个最大广义特征值所对应的特征向量组成的矩阵

□ 多分类LDA将样本投影到N-1维空间,N-1通常远小于数据原有的 属性数,因此LDA也被视为一种监督降维技术。

多分类学习

多分类学习



- □ 多分类学习方法
 - 二分类学习方法推广到多类
 - 利用二分类学习器解决多分类问题(常用)
 - 对问题进行拆分,为拆出的每个二分类任务训练一个分类器
 - 对于每个分类器的预测结果进行集成以获得最终的多分类结果

□ 拆分策略


- -xy (One vs. One, OvO)
- 一对其余(One vs. Rest, OvR)
- 多对多 (Many vs. Many, MvM)

多分类学习 - 一对一



- □ 拆分阶段
 - N个类别两两配对
 - N(N-1)/2 个二类任务
 - 各个二类任务学习分类器
 - N(N-1)/2 个二类分类器

- □ 测试阶段
 - 新样本提交给所有分类器预测
 - N(N-1)/2 个分类结果
 - 投票产生最终分类结果
 - 被预测最多的类别为最终类别




多分类学习 - 一对其余



- □ 任务拆分
 - 某一类作为正例,其他反例
 - N 个二类任务
 - 各个二类任务学习分类器
 - N 个二类分类器

- □ 测试阶段
 - 新样本提交给所有分类器预测
 - N 个分类结果
 - 比较各分类器预测置信度
 - 置信度最大类别作为最终类别





多分类学习 - 两种策略比较



- ▶ OvO的存储开销和测试时间开销通常比OvR大:
 OvR只需训练C个分类器,
 而OvO需训练C(C-1)/2个分类器。
- ➤ 类别多时,OvO的训练时 间开销通常比OvR小:训练时,OvR的每个分类器 均使用全部训练样本,而 OvO的每个分类器仅用到 两个类样本;
- 预测性能差不多:至于预测性能,则取决于具体的数据分布,在多数情形下两者差不多。







多分类学习 - 多对多




- □ 多对多 (Many vs Many, MvM)
 - 若干类作为正类,若干类作为反类
- □ 纠错输出码 (Error Correcting Output Code, ECOC)

编码:对N个类别做M次划分,每次划分将一部分类别划为正类,一部分划为反类 距离最小的类别为最终类别 解码:测试样本交给M个分类器预测 长度为M的编码预测

多分类学习 - 多对多



■ 纠错输出码(Error Correcting Output Code, ECOC)



(a) 二元 ECOC 码

[Dietterich and Bakiri,1995]

(b) 三元 ECOC 码

[Allwein et al. 2000]

- ECOC编码对分类器错误有一定容忍和修正能力,编码越长、纠错能力越强
- 对同等长度的编码,理论上来说,任意两个类别之间的编码距离越远,则 纠错能力越强

类别不平衡问题

类别不平衡问题




- □ 类别不平衡 (class imbalance)
 - 不同类别训练样例数相差很大情况(正类为小类)

类别平衡正例预测
$$\frac{y}{1-y} > 1$$




$$\frac{y}{1-y} > \frac{m^+}{m^-}$$
 正负类比例



- □ 再缩放
 - 欠采样 (undersampling)
 - 去除一些反例使正反例数目接近(EasyEnsemble [Liu et al.,2009])
 - 过采样 (oversampling)
 - 增加一些正例使正反例数目接近(SMOTE [Chawla et al.2002])
 - 國值移动 (threshold-moving)




➤ 过采样 (oversampling):



- ✓ 样本复制
- ✓ 样本插值
- ✓ 样本生成 (GAN)

[1] Chawla N V, Bowyer K W, et al. **SMOTE: Synthetic Minority Over-Sampling Technique**. *JAIR*, 2002.

> 欠采样 (undersampling)



[2] Xu-Ying Liu, Jianxin Wu, Zhi-Hua Zhou. Exploratory Undersampling for Class-Imbalance Learning. *IEEE TSMCB*, 2009.

优化提要



- □ 各任务下(回归、分类)各个模型优化的目标
 - 最小二乘法:最小化均方误差
 - 对数几率回归:最大化样本分布似然
 - 线性判别分析:投影空间内最小(大)化类内(间)散度

- □ 参数的优化方法
 - 最小二乘法:线性代数
 - 对数几率回归: 凸优化梯度下降、牛顿法
 - 线性判别分析:矩阵论、广义瑞利商

总结



- □ 线性回归
 - 最小二乘法 (最小化均方误差)
- □ 二分类任务
 - 对数几率回归
 - 单位阶跃函数、对数几率函数、极大似然法
 - 线性判别分析
 - 最大化广义瑞利商
- □ 多分类学习
 - \(\forall \) \(\fo
 - 一对其余
 - 多对多
 - 纠错输出码
- □ 类别不平衡问题
 - 基本策略:再缩放