

# 深度生成模型 **Deep Generative Model**







http://speech.ee.ntu.edu.tw/~tlkagk/courses MLDS18.html 李宏毅 台湾大学

## 目录(CONTENT)



- 01 引言(Introduction)
- 02 生成对抗网络(Generative Adversarial Network)
- 03 变分自编码器(Variational AutoEncoder)
- 04 小结与资源 (Take Home Message and Resource)

## 深度生成模型 (Deep Generative Model)



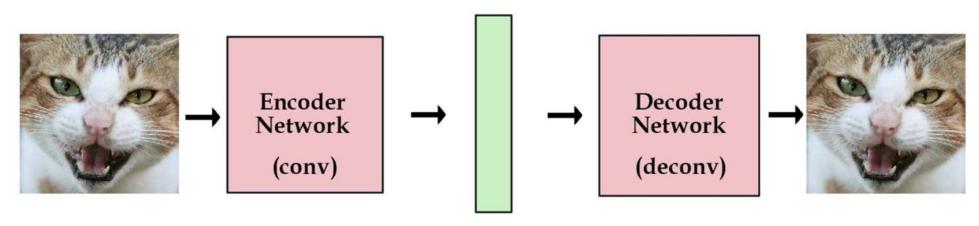


## 变分自编码器

Variational AutoEncoder



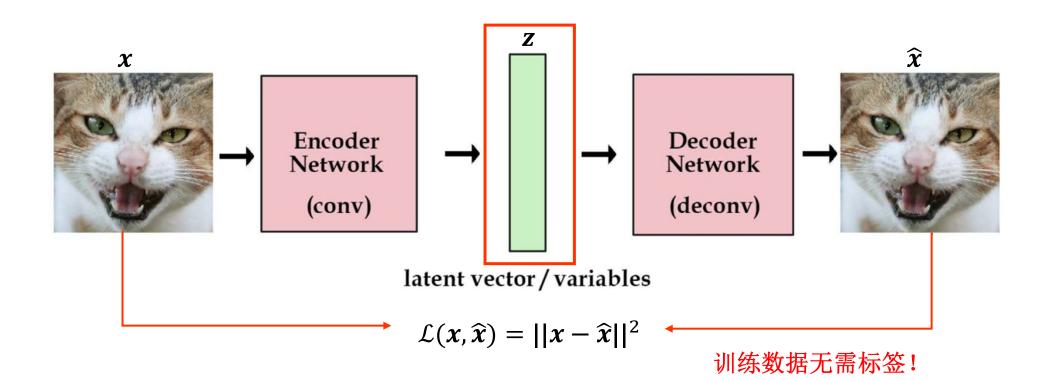
- ■回顾: 自编码器 (Autoencoder)
  - 编码器 (Encoder) 将输入数据映射为一个隐含变量
  - 解码器 (Decoder) 从隐含变量中重构出原始输入数据



latent vector / variables

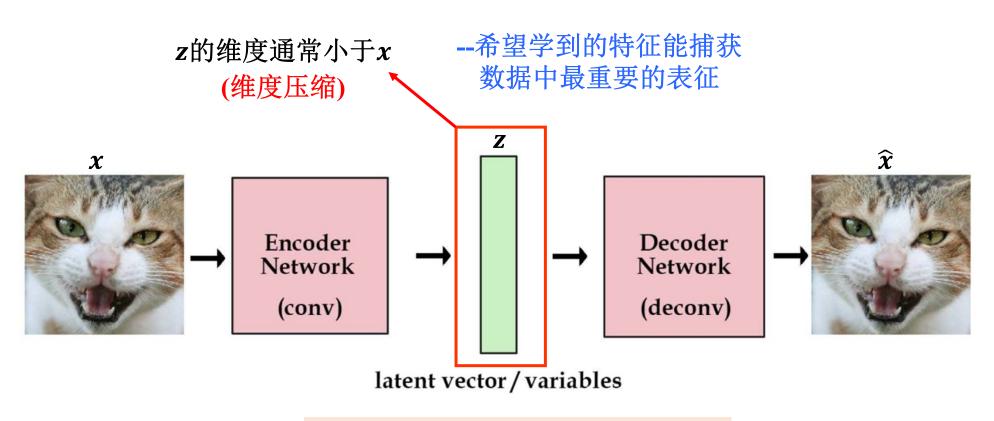


- ■回顾: 自编码器 (Autoencoder)
  - 最小化重构误差,使网络学会捕获对数据的隐含变量





■回顾: 自编码器 (Autoencoder)

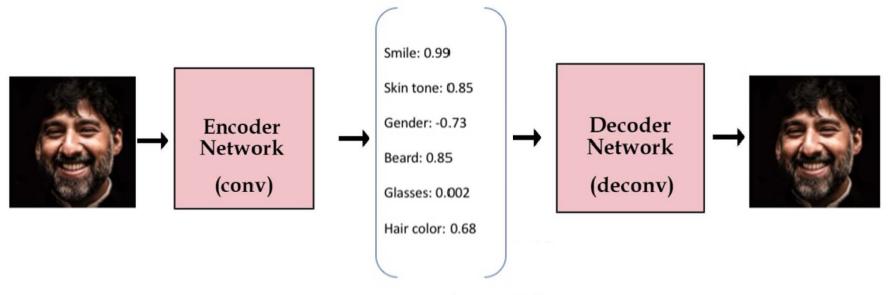


自编码是一种数据压缩方式

**Autoencoding** = **Auto**matically **encoding** data



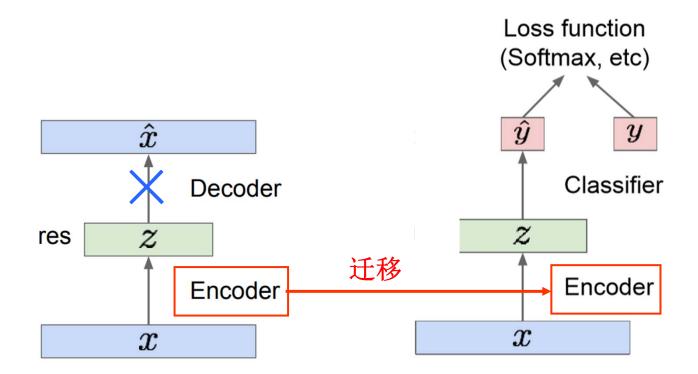
- ■回顾: 自编码器 (Autoencoder)
  - 隐含变量可表征输入数据的某些结构或属性



latent vector / variables



- ■回顾: 自编码器(Autoencoder)
  - 训练完成后, Encoder能够将训练数据映射至一个有效地隐含空间
  - 可抛开Decoder,将学好的Encoder迁移至其他任务中





■自编码器是否能生成新的图像?

AutoEncoder

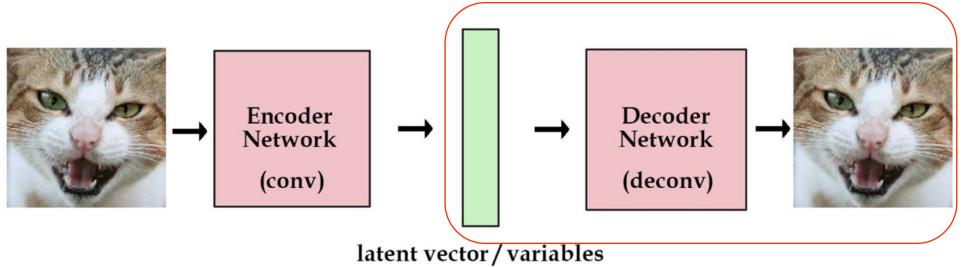






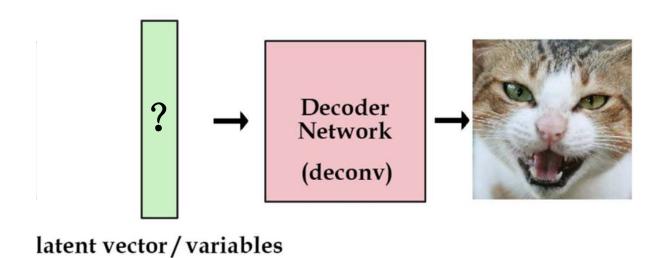
■自编码器是否能生成新的图像?

### 生成图像的部分





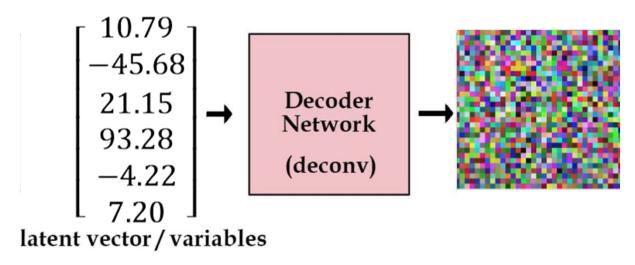
- ■自编码器是否能生成新的图像?
  - > 测试阶段
    - 不知道如何创建需要输入的隐变量



生成图像的部分



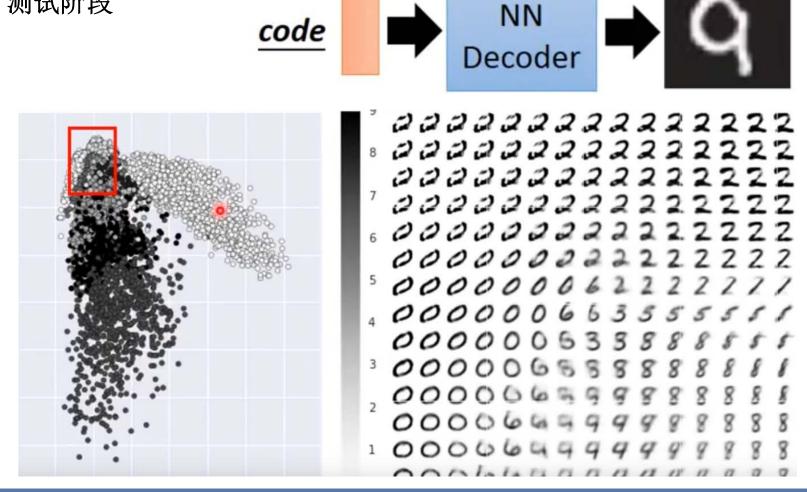
- ■自编码器是否能生成新的图像?
  - > 测试阶段
    - 假设输入一组随机的向量,我们很大程度上将得到一个噪声图像



生成图像的部分

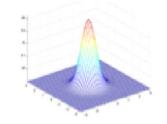


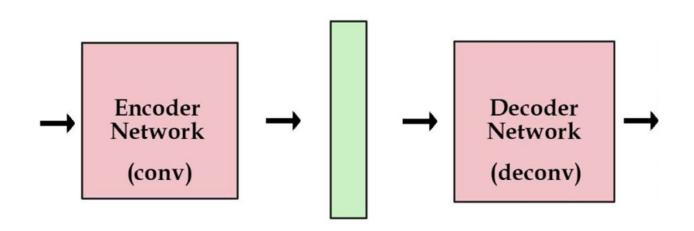
- ■自编码器是否能生成新的图像?
  - > 测试阶段





- ■自编码器是否能生成新的图像?
  - ▶ 解决方案—变分自编码器
    - 对Encoder增加约束,强制其产生的隐含变量基本服从某种分布

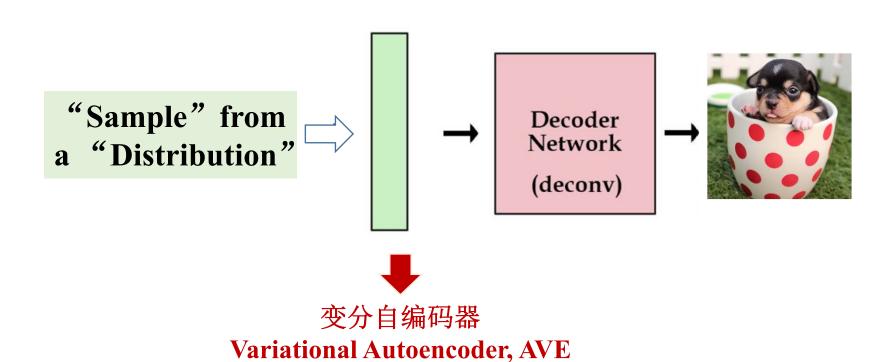




Latent distributions

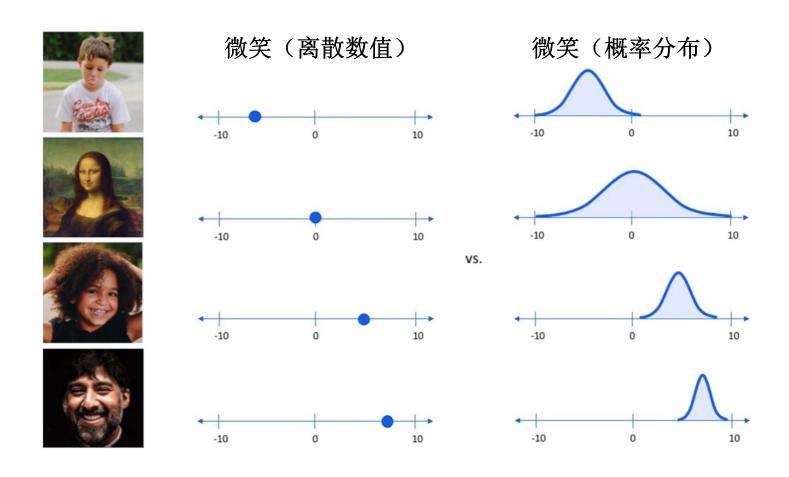


- ■自编码器是否能生成新的图像?
  - ▶ 解决方案—变分自编码器
    - 测试时,从该分布中采样作为隐含量,并传递到解码器,生成新图像



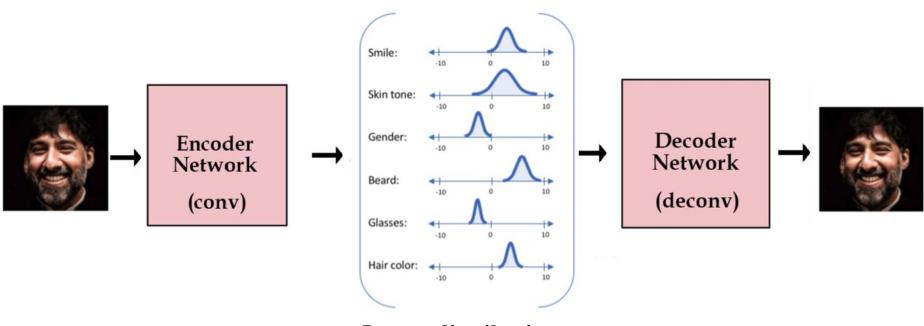


• 隐含变量的每个元素由原先的"单值" => "取值的概率分布"





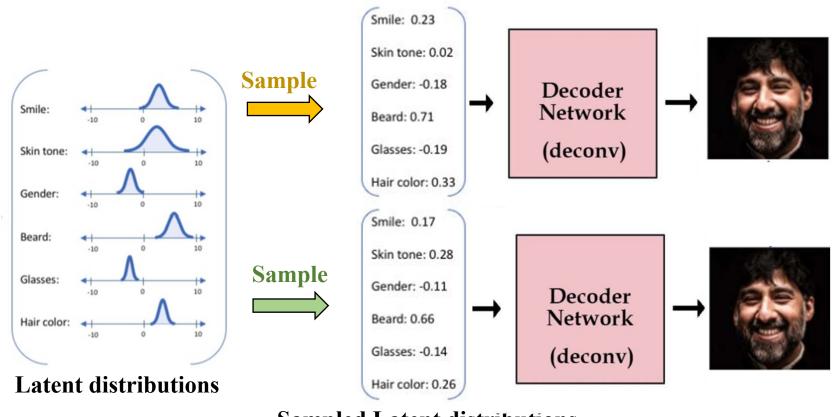
• 生成图像(即对隐含变量解码)时,从每个隐含分布中随机采样,生成 一个向量作为解码器模型的输入



Latent distributions

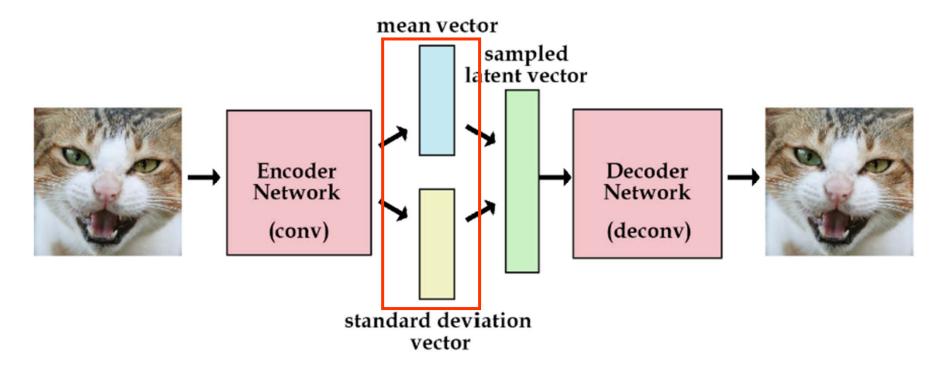


• 在连续平滑的隐含分布空间随机采样,彼此相邻的值具有类似重构



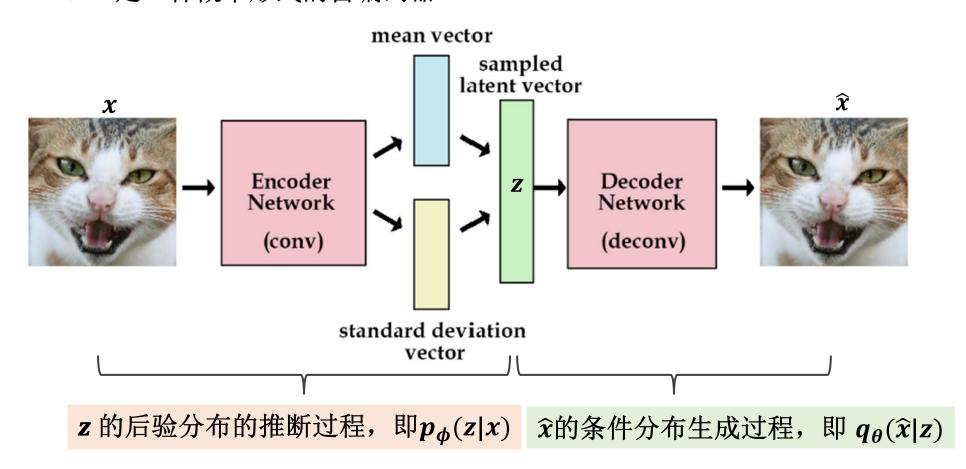


- 通常假设采样的隐含变量服从正态分布  $\mathcal{N}(\mu, \sigma^2)$
- 从均值分布和标准差分布中随机抽取,计算隐含变量



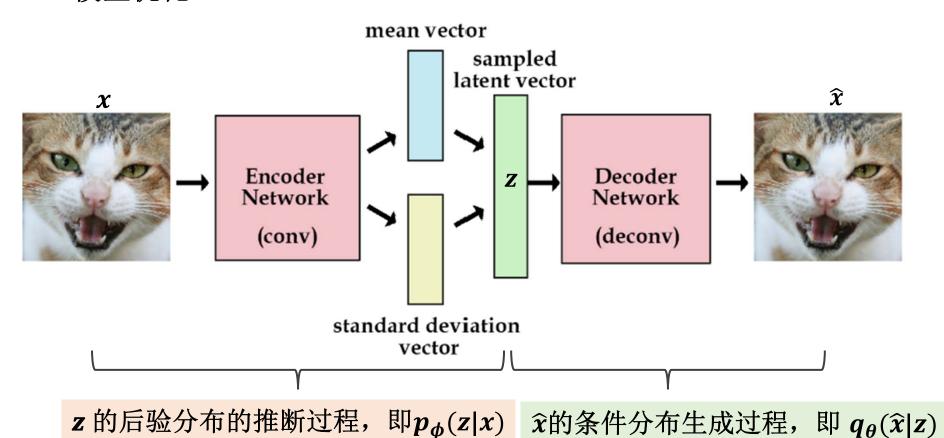


• VAE是一种概率形式的自编码器





■ 模型优化

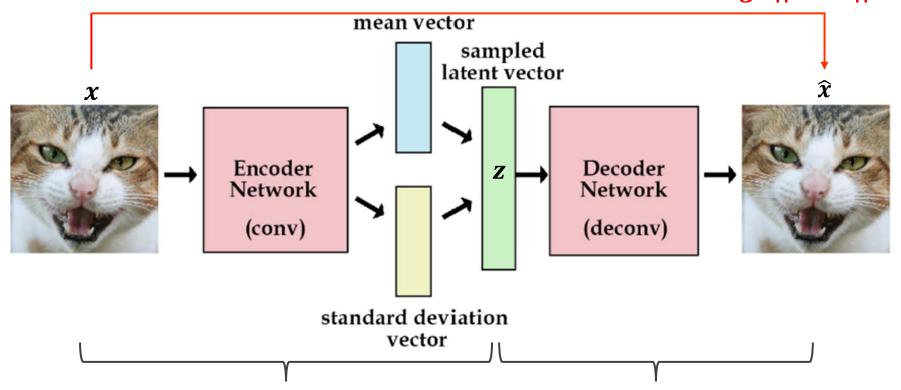


 $\mathcal{L}(\boldsymbol{\phi}, \boldsymbol{\theta}) =$ 重构误差+约束项



模型优化





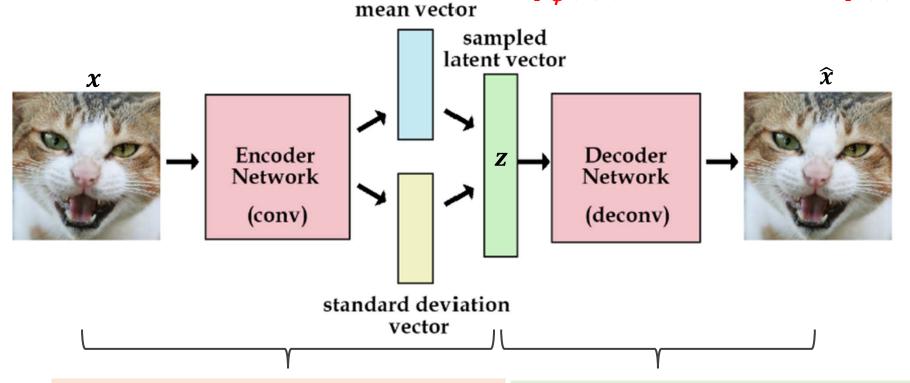
z的后验分布的推断过程,即 $p_{\phi}(z|x)$   $\hat{x}$ 的条件分布生成过程,即  $q_{\theta}(\hat{x}|z)$ 

$$\mathcal{L}(\boldsymbol{\phi}, \boldsymbol{\theta}) =$$
重构误差+ 约束项



■ 模型优化

### $p_{\phi}(z|x)$ 尽可能的接近先验p(z)



z的后验分布的推断过程,即 $p_{\phi}(z|x)$ 

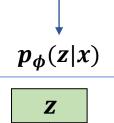
 $\hat{x}$ 的条件分布生成过程,即  $q_{\theta}(\hat{x}|z)$ 

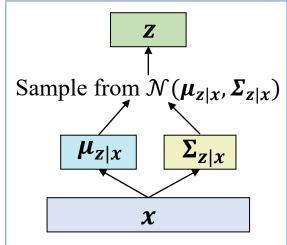
 $\mathcal{L}(\boldsymbol{\phi}, \boldsymbol{\theta}) =$ 重构误差+ 约束项



- 模型优化
  - > 约束项

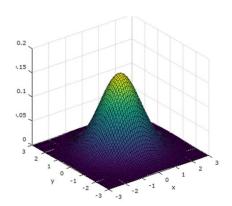
• 目标:  $p_{\phi}(z|x)$  尽可能的接近先验 p(z)





**Encoder** 

### 通常假设 $p(z)\sim\mathcal{N}(0,1)$





- 模型优化
  - 正则项

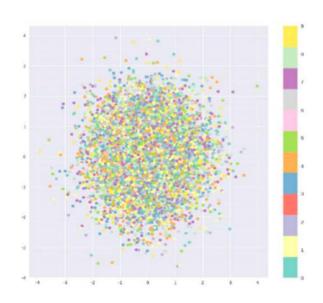
 $p(z) \sim \mathcal{N}(0,1)$ 

- 目标:  $p_{\phi}(z|x)$  尽可能的接近先验p(z)

采用KL散度,即: 
$$D_{KL}\left(\mathbf{p_{\phi}}(\mathbf{z}|\mathbf{x}) \parallel \mathbf{p}(\mathbf{z})\right)$$
  

$$= D_{KL}\left(\mathcal{N}\left(\mathbf{\mu_{z|x}}, \mathbf{\Sigma_{z|x}}\right) \parallel \mathcal{N}(0,1)\right)$$

$$= -\frac{1}{2}\sum_{j}^{K}(\mathbf{\Sigma_{z|x_{j}}} + \mathbf{\mu_{z|x_{j}}}^{2} - 1 - \log \mathbf{\Sigma_{z|x_{j}}})$$

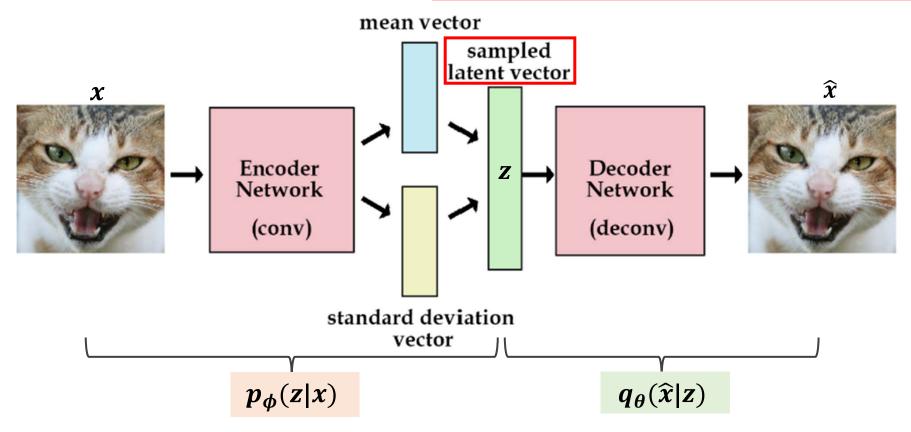


鼓励Encoder的输出分布 $p_{\phi}(z|x)$ 均衡地分布在隐变 量的先验空间



■ 模型优化

问题: sampling layer无法后向传递梯度!

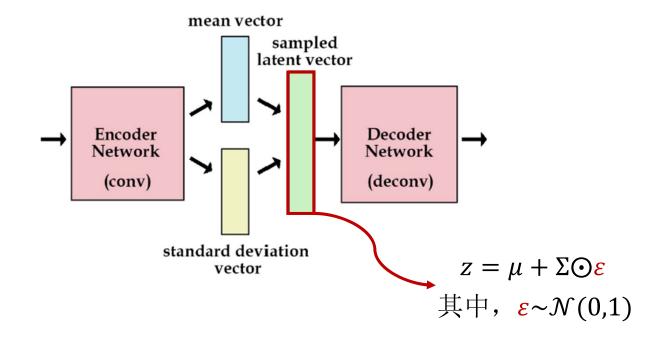


 $\mathcal{L}(\boldsymbol{\phi},\boldsymbol{\theta})$  =重构误差 + 正则项



- 模型优化
  - ➤ 问题: Sampling layer无法后向传递梯度!

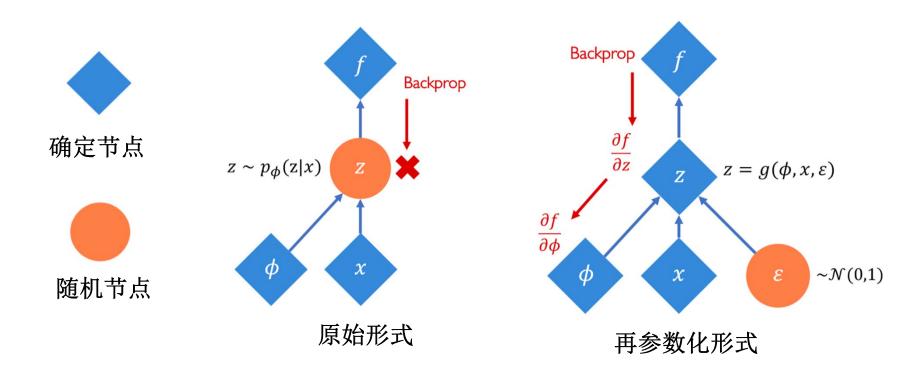
解决方案: 再参数化(Reparameterization Trick )





- 模型优化
  - ➤ 问题: Sampling layer无法后向传递梯度!

解决方案:对Sampling layer再参数化 (Reparameterization Trick )





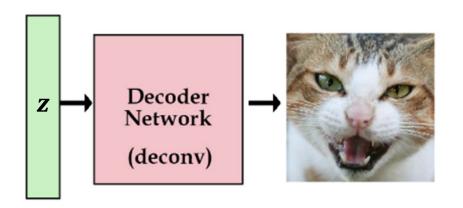
### ■ 模型优化

```
mport tensorflow as tf
def gaussian_MLP_encoder(x, n_hidden, n_output, keep_prob):
    gaussian_params = tf.matmul(h1, wo) + bo
   # The mean parameter is unconstrained
   mean = gaussian params[:, :n output]
    stddev = 1e-6 + tf.nn.softplus(gaussian params[:, n output:])
    return mean, stddev
def autoencoder(x_hat, x, dim_img, dim_z, n_hidden, keep_prob):
   mu, sigma = gaussian_MLP_encoder(x_hat, n_hidden, dim_z, keep_prob)
   # sampling by re-parameterization technique
   z = mu + sigma * tf.random normal(tf.shape(mu), 0, 1, dtype=tf.float32)
   y = bernoulli MLP decoder(z, n hidden, dim img, keep prob)
   marginal_likelihood = tf.reduce_sum(x * tf.log(y) + (1 - x) * tf.log(1 - y), 1)
   KL_divergence = 0.5 * tf.reduce_sum(tf.square(mu) + tf.square(sigma) - tf.log(1e-8 + tf.square(sigma)) - 1, 1)
    ELBO = tf.reduce_mean(marginal_likelihood) - tf.reduce_mean(KL_divergence)
    loss = -ELBO
```



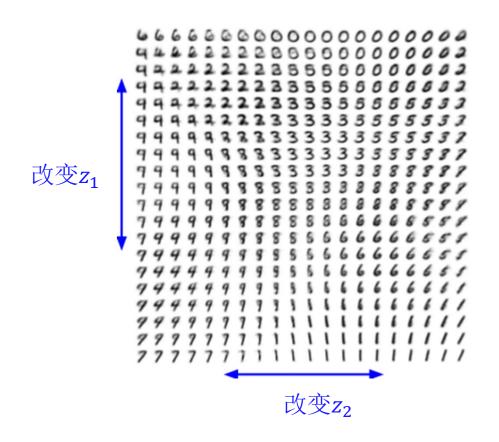
### ■ 数据生成

• 从先验分布中随机抽取z送入Decoder中,则可随机生成相应的图像





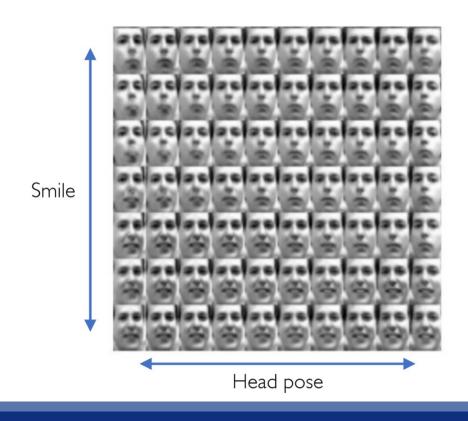
- 数据生成
  - 例:在手写数字数据集上训练,且隐含变量 $\mathbf{z} = [z_1, z_2]^T$ 为二维向量





### ■ 数据生成

- Disentangled VAE
  - 在隐含变量中,每个点之间彼此无关,各自学习输入数据中不同隐含特征
  - 对z增加约束,使每一维的隐含分布相互独立





### ■ 数据生成

- ➤ Disentangled AVE
  - 在隐含变量中,每个点之间彼此无关,各自学习输入数据中不同隐含特征
  - 对z增加约束,使每一维的隐含分布相互独立



### Head pose

对隐含变量的某一维度进行平滑扰动,观察相应所生成的数据,来理解该维度隐变量的物理含义



### ■ 小结

- 自编码器 + 概率分布估计 => 生成模型,可生成新的数据
- 隐含变量是对可观测数据的一种压缩表征
- 通过重构的方式进行无监督学习,降低对数据标注的要求
- 隐含变量的各维度对应着可解释的物理含义

Variational AutoEncoder



### 生成对抗网络 (GAN)



### ■小结

- 关注于数据生成问题,不涉及对数据分布的显式建模问题
- 借助博弈思想:通过"两方博弈",从训练数据分布中学习生成新数据

#### • 优点与不足:

- --优: 能生成非常生动清晰的样本
- --缺:训练过程不易稳定,需要更多的训练技巧

#### • 活跃研究领域:

- --寻求更好的损失函数,更稳定的训练策略 (Wasserstein GAN, LSGAN等)
- --广泛的应用(图像转换、动漫生成、语音识别、去雾等)

### 深度生成模型 (Deep Generative Model)



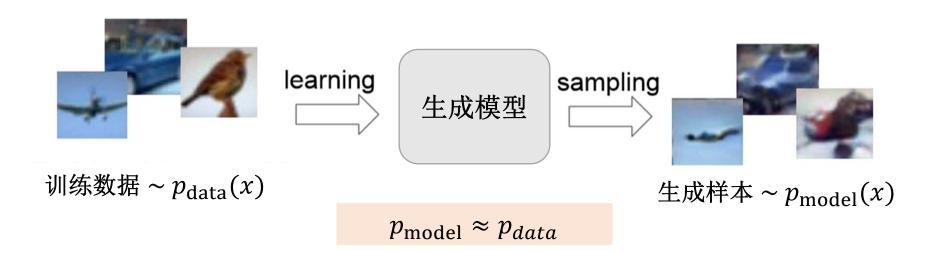


## 小结和资源 Take Home Message and Resource



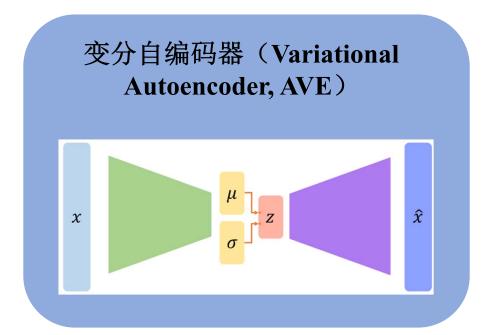
#### ■生成网络

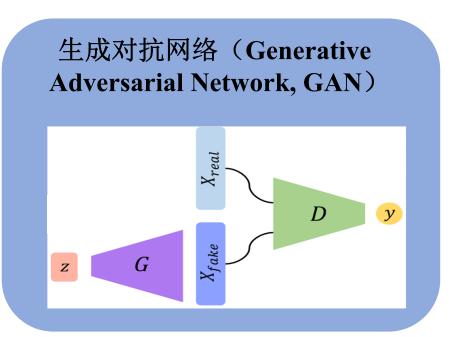
• 希望模型生成的新数据与训练数据的真实分布尽可能地相似





■两种生成模型







■ 变分自编码器(VAE)

普通的自编码器	变分自编码器
(Normal AutoEncoder)	(Variational AutoEncoder)
• 作用	• 作用
学习输入数据的隐含表征	学习生成新的可观测数据
• 只能重构数据,无法生成新数据	
• 优化: min 重构误差	• 优化: min (重构误差+ <mark>隐变量的约束项</mark> ) 隐变量从正态分布中随机抽取



■ 变分自编码器(VAE)

生成对抗网络 (Generative Adversarial Network)	变分自编码器 (Variational AutoEncoder)
• 隐式密度估计	• 显式密度估计
<ul><li>网络结构:</li><li> Generator + Discriminator</li></ul>	• 网络结构: Encoder + Decoder
<ul><li>如何学习:</li><li> Minmax Game 交替训练</li></ul>	• 如何学习: min (重构误差+隐变量的约束项)





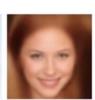
















GAN生成图像的质量更清晰!

#### 资源参考 (Resource and Reference)



#### > Paper

- [1] Karras et al., A Style-Based Generator Architecture for Generative Adversarial Networks, CVPR2019.
- [2] Goodfellow, et al., Generative adversarial nets. NIPS2014.
- [3] Ledig et al., Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network. CVPR2017.
- [4] Isola et al., Image-to-Image Translation with Conditional Adversarial Networks. CVPR2017.
- [5] C Doersch, Tutorial on Variational Autoencoders. arXiv abs/1606.05908.
- [6] Higgins *et al.*, β-VAE: Learning Basic Visual Concepts with a Constrained Variational Framework. ICLR2017.
- [7] Radford et al., Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks, ICLR 2016.

#### Other useful links ZOO

https://github.com/hindupuravinash/the-gan-zoo GAN ZOO

https://github.com/soumith/ganhacks Tips for Training GANs

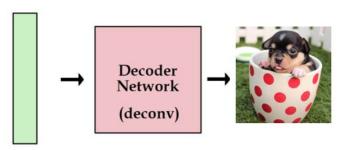
#### VAE



■ VAE优化密度函数(似然函数)

$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

- □ 通过附加的隐变量 z 对密度函数进行建模
- □ 全概率公式,对所有可能的z求期望
- □ 最大化该似然函数



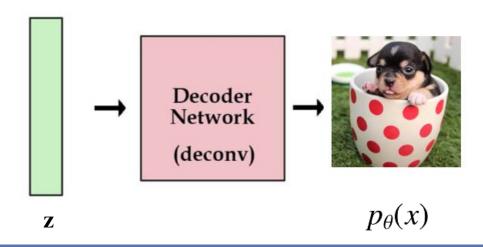
#### VAE



■ VAE优化密度函数(似然函数)

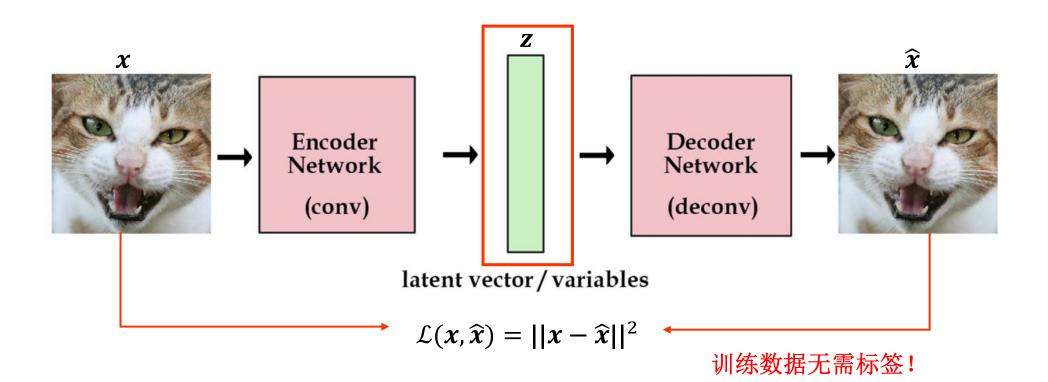
$$p_{\theta}(x) = \int p_{\theta}(z) p_{\theta}(x|z) dz$$

- □通过附加的隐变量z对密度函数进行建模
- □ 全概率公式,对所有可能的 z 求期望
- □ 最大化该似然函数



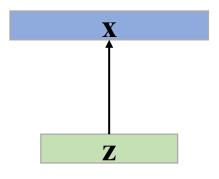


■ 自编码器: 能够重建数据





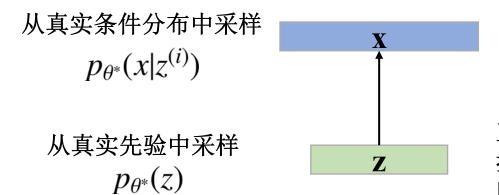
- 变分自编码器:在自编码器中引入随机因子获得的一种模型,从该模型中 采样从而生成新数据
- 训练数据  $\{x^{(i)}\}_{i=1}^{N}$  由隐变量  $\mathbf{z}$  生成



直观上讲: z的每个维度是训练数据中的某个属性的变化程度,如脸的朝向、笑容程度、头发多少等



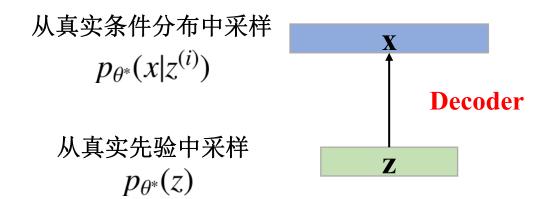
- 变分自编码器:在自编码器中引入随机因子获得的一种模型,从该模型中 采样从而生成新数据
- 训练数据  $\{x^{(i)}\}_{i=1}^{N}$  由隐变量  $\mathbf{z}$  生成



直观上讲: z的每个维度是训练数据中的某个属性的变化程度,如脸的朝向、笑容程度、头发多少等



- 目标: 估计该生成模型中的参数  $\theta^*$
- 选择简单的先验 p(z) 即可,例如高斯分布
- 估计 p(x|z) 很复杂,用NN对其进行建模

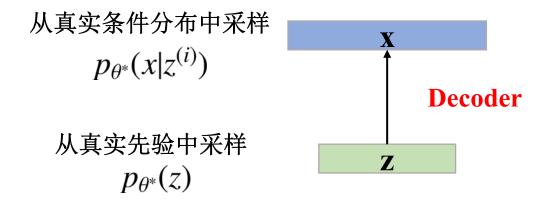




■ 训练模型:最大化似然函数,从而得到最优参数  $\theta^*$ 

$$p_{\theta}(x) = \int p_{\theta}(z) p_{\theta}(x|z) dz$$

■ 问题: 该积分似然函数的最大化很难求解





■ 训练模型:最大化似然函数,从而得到最优参数  $\theta^*$ 

$$p_{\theta}(x) = \int p_{\theta}(z) p_{\theta}(x|z) dz$$

□高斯函数



$$p_{\theta}(x) = \int p_{\theta}(z) p_{\theta}(x|z) dz$$

- □高斯函数
- □神经网络



$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

- □高斯函数
- □神经网络
- □此积分难算



$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

- □高斯函数
- □神经网络
- □此积分难算
- □导致后验概率也无法计算

$$p_{\theta}(z|x) = p_{\theta}(x|z)p_{\theta}(z)/p_{\theta}(x)$$



$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

- □高斯函数
- □神经网络
- □此积分难算
- □导致后验概率也无法计算

$$p_{\theta}(z|x) = p_{\theta}(x|z)p_{\theta}(z)/p_{\theta}(x)$$



■ 训练模型:最大化似然函数,从而得到最优参数  $\theta^*$ 

$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

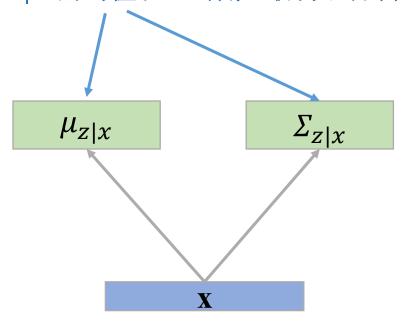
#### □解决方案

- 用decoder建模  $p_{\theta}(x|z)$
- 用另外一个网络  $q_{\phi}(z|x)$  (encoder network)建模  $p_{\theta}(z|x)$



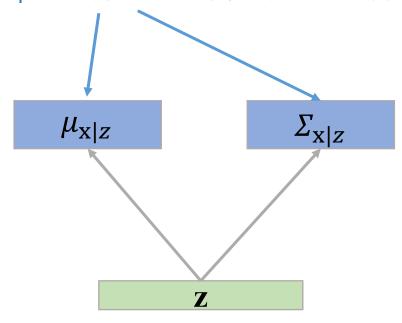
■ VAE网络: 建模数据的生成概率,encoder和decoder也要是概率性模型 即将随机因子引入网络

z|x的均值和(对角)协方差矩阵



**Encoder**  $q_{\phi}(z|x)$ 

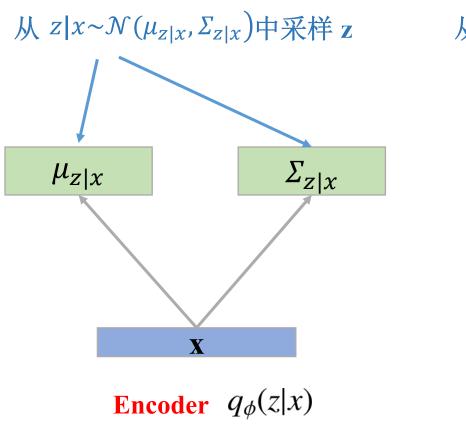
x|z的均值和(对角)协方差矩阵

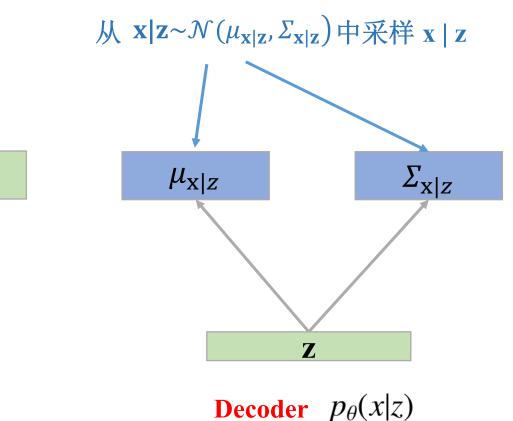


**Decoder**  $p_{\theta}(x|z)$ 



■ VAE网络: 建模数据的生成概率,encoder和decoder也要是概率性模型 即将随机因子引入网络







$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

$$\begin{split} \log p_{\theta}(x^{(i)}) &= \mathbf{E}_{z \sim q_{\theta}(z|x^{(i)})}[\log p_{\theta}(x^{(i)})] \\ &= \mathbf{E}_{z}[\log \frac{p_{\theta}(x^{(i)}|z)p_{\theta}(z)}{p_{\theta}(z|x^{(i)})}] \qquad \text{贝叶斯公式} \\ &= \mathbf{E}_{z}[\log \frac{p_{\theta}(x^{(i)}|z)p_{\theta}(z)}{p_{\theta}(z|x^{(i)})} \frac{q_{\theta}(z|x^{(i)})}{q_{\theta}(z|x^{(i)})}] \\ &= \mathbf{E}_{z}[\log p_{\theta}(x^{(i)}|z)] - \mathbf{E}_{z}[\log \frac{q_{\theta}(z|x^{(i)})}{p_{\theta}(z)}] + \mathbf{E}_{z}[\log \frac{q_{\theta}(z|x^{(i)})}{p_{\theta}(x^{(i)}|z)}] \\ &= \mathbf{E}_{z}[\log p_{\theta}(x^{(i)}|z)] - D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z)\right)} + D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z|x^{(i)})\right)}_{p_{\theta}(z|x^{(i)})} \\ &= \mathbf{E}_{z}[\log p_{\theta}(x^{(i)}|z)] - D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z)\right)}_{p_{\theta}(z)} + D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z|x^{(i)})\right)}_{p_{\theta}(z|x^{(i)})} \\ &= \mathbf{E}_{z}[\log p_{\theta}(x^{(i)}|z)] - D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z)\right)}_{p_{\theta}(z)} + D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z|x^{(i)})\right)}_{p_{\theta}(z|x^{(i)})} \\ &= \mathbf{E}_{z}[\log p_{\theta}(x^{(i)}|z)] - D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z)\right)}_{p_{\theta}(z)} + D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z|x^{(i)})\right)}_{p_{\theta}(z|x^{(i)})} \\ &= \mathbf{E}_{z}[\log p_{\theta}(x^{(i)}|z)] - D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z)\right)}_{p_{\theta}(z)} + \mathbf{E}_{z}[\log p_{\theta}(x^{(i)}|z)] - D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right) \mid p_{\theta}(z)\right)}_{p_{\theta}(z)} + D_{KL} \underbrace{\left(q_{\phi}(z|x^{(i)})\right)}_{p_{\theta}(z)} + D_{KL} \underbrace$$



■ 训练模型:最大化似然函数,从而得到最优参数  $\theta^*$ 

$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

$$\log p_{\theta}(x^{(i)}) = \mathbf{E}_{z \sim q_{\theta}(z|x^{(i)})}[\log p_{\theta}(x^{(i)})]$$

$$= \mathbb{E}_{z}[\log p_{\theta}(x^{(i)} | z)] - D_{KL}(q_{\phi}(z | x^{(i)}) || p_{\theta}(z)) + D_{KL}(q_{\phi}(z | x^{(i)}) || p_{\theta}(z | x^{(i)}))$$

 $\square$   $p_{\theta}(x^{(i)}|z)$  由Decoder给出,通过采样可计算该项



$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

$$\log p_{\theta}(x^{(i)}) = \mathbf{E}_{z \sim q_{\theta}(z|x^{(i)})}[\log p_{\theta}(x^{(i)})]$$

$$= \mathbf{E}_{z}[\log p_{\theta}(x^{(i)} | z)] - D_{KL}(q_{\phi}(z | x^{(i)}) || p_{\theta}(z)) + D_{KL}(q_{\phi}(z | x^{(i)}) || p_{\theta}(z | x^{(i)}))$$

- $\square$   $p_{\theta}(x^{(i)}|z)$  由Decoder给出,通过采样可计算该项
- □ Encoder的输出(高斯函数)和z的先验间的KL散度,有闭形式解



$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

$$\log p_{\theta}(x^{(i)}) = \mathbf{E}_{z \sim q_{\theta}(z|x^{(i)})}[\log p_{\theta}(x^{(i)})]$$

$$= \mathbf{E}_{z}[\log p_{\theta}(x^{(i)} \mid z)] - D_{KL}(q_{\phi}(z \mid x^{(i)}) \parallel p_{\theta}(z)) + D_{KL}(q_{\phi}(z \mid x^{(i)}) \parallel p_{\theta}(z \mid x^{(i)}))$$

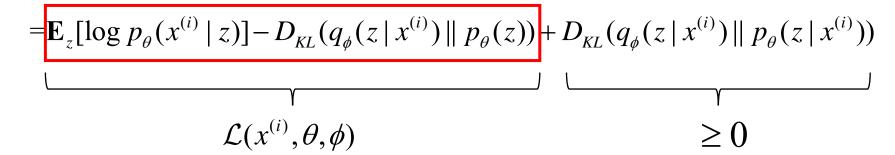
- $\square$   $p_{\theta}(x^{(i)}|z)$  由Decoder给出,通过采样可计算该项
- □ Encoder的输出(高斯函数)和z的先验间的KL散度,有闭形式解
- $\square$   $p_{\theta}(z|x^{(i)})$  无法计算,此项不可解,但是此项一定大于零(由于KL散度的定义)



■ 训练模型:最大化似然函数,从而得到最优参数  $\theta^*$ 

$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

$$\log p_{\theta}(x^{(i)}) = \mathbf{E}_{z \sim q_{\theta}(z|x^{(i)})}[\log p_{\theta}(x^{(i)})]$$



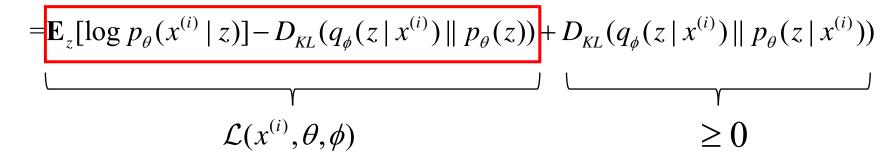
似然函数的下界, 可计算梯度并进行优化



■ 训练模型:最大化似然函数,从而得到最优参数  $\theta^*$ 

$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

$$\log p_{\theta}(x^{(i)}) = \mathbf{E}_{z \sim q_{\theta}(z|x^{(i)})}[\log p_{\theta}(x^{(i)})]$$



训练模型: 最优化似然函数的下界

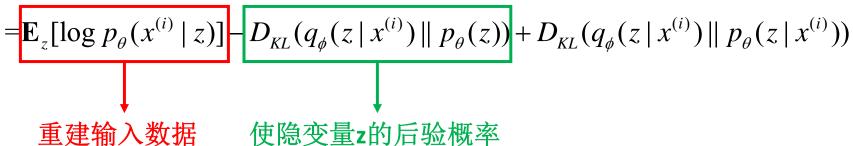
$$\theta^*, \phi^* = \arg\max_{\theta, \phi} \sum_{i=1}^{N} \mathcal{L}(x^{(i)}, \theta, \phi)$$



■ 训练模型:最大化似然函数,从而得到最优参数  $\theta^*$ 

$$p_{\theta}(x) = \int p_{\theta}(z)p_{\theta}(x|z)dz$$

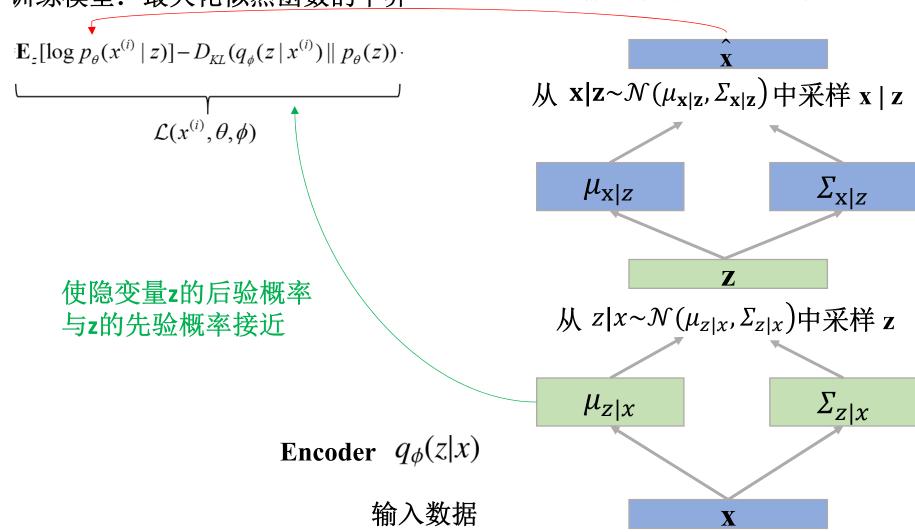
$$\log p_{\theta}(x^{(i)}) = \mathbf{E}_{z \sim q_{\theta}(z|x^{(i)})}[\log p_{\theta}(x^{(i)})]$$



与z的先验概率接近

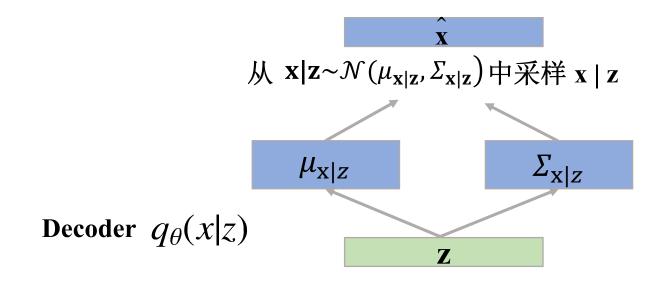


■ 训练模型: 最大化似然函数的下界 最大化重建输入数据的似然函数





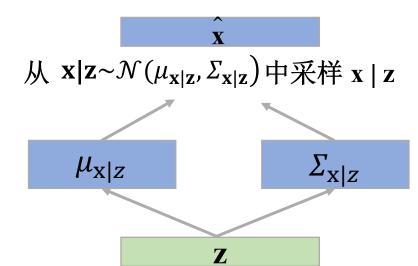
- 训练模型: 最大化似然函数的下界
  - □ 用Decoder生成图像
  - □ 从z的先验分布中采样



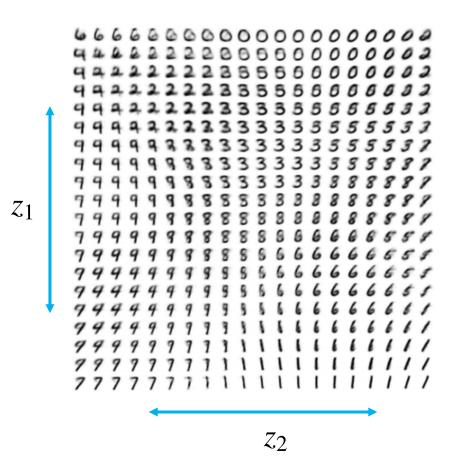
从  $z \sim \mathcal{N}(0,I)$  中采样 **z** 



- 训练模型: 最大化似然函数的下界
  - □ 用Decoder生成图像
  - □ 从z的先验分布中采样



从  $z \sim \mathcal{N}(0,I)$  中采样 **z** 





**■** GAN





■ GAN

